

Práctica MLOps_IA – Guillermo Barrio

Contenido del repositorio

Este documento es la memoria del trabajo final del Programa Técnico Avanzado DevOps con IA y LLMOps, que se encuentra depositado en repositorio de GitHub [Practica_DevOps_2026](#). Quizás por deformación profesional, uso la primera persona del plural, aunque el trabajo ha sido individual. El trabajo consiste en el **despliegue en Google Cloud** de una aplicación que redacta un comentario financiero, utilizando los LLM de Gemini. La aplicación se encuentra en esta url:

<https://autobloomberg-yn34vb66rq-ez.a.run.app/>

Además, se explora el **uso de modelos en local**, concretamente Gemma 3 y Gemma 2, bajados de Ollama, en una app desarrollada en Google Colab.

En este apartado describimos el contenido del repositorio, para pasar a explicar las apps, y su proceso de diseño, en el resto de esta memoria. El repo contiene estos documentos y carpetas:

- **app-comentario.py** contiene el código de la app en Python
- **Requirements.txt** contiene las librerías necesarias
- **Dockerfile** contiene el código para el despliegue de la app en Google Run
- **Ollama_Main_Files** contiene el código de la app con modelos locales, y el requirement.txt correspondiente
- **Ollama_Notebooks** contiene seis cuadernos de Google Colab, donde se lleva a cabo el finetuning del modelo Gemma3, y su evaluación mediante Ragas, así como la creación del fichero del código de la app. entre otras actividades
- **Ollama_Datasets** contiene los datasets de train y test, utilizados en el finetuning y Ragas, respectivamente
- **Ollama_Ragas** contiene los ficheros de la evaluación Ragas
- **Ejemplo_Ficheros_Necesarios** contiene una muestra de los 4 ficheros que son necesarios para generar el comentario, y que pide la app.

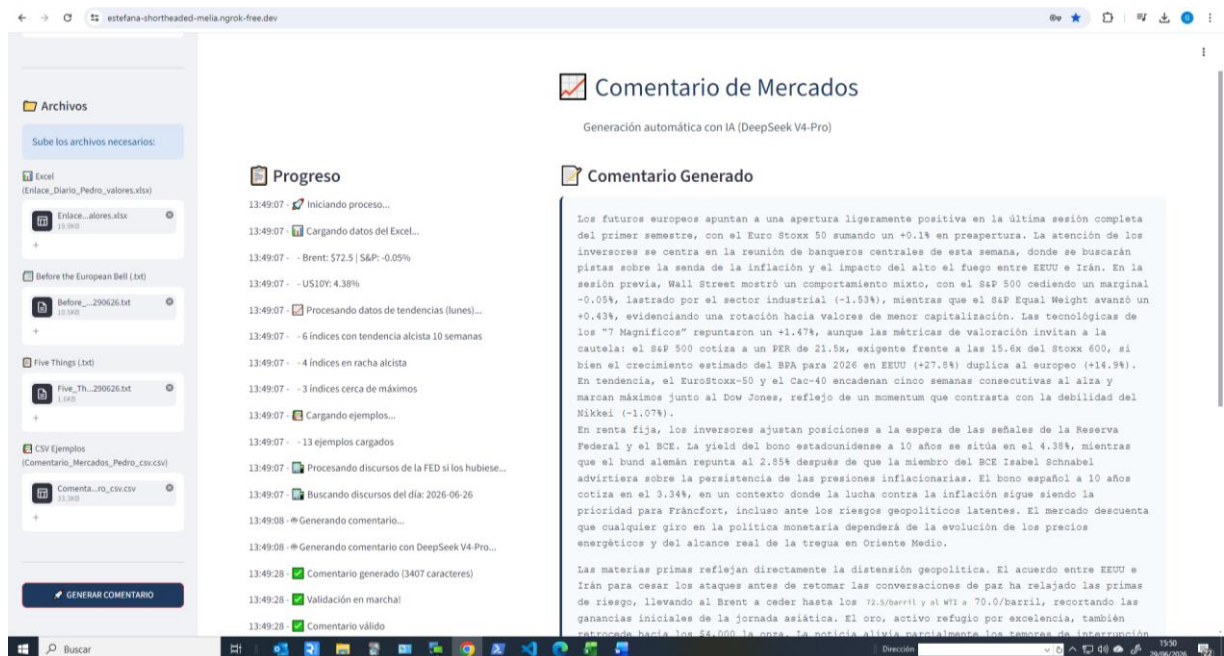
A continuación, describimos ambas partes de la práctica: primero el despliegue en Google, y después el uso de modelos Gemma en local.

Despliegue en Google Cloud - Introducción y presentación

En este documento describo brevemente la práctica del curso de MLOps-IA en su parte de despliegue en Google Colab. En esencia, el proyecto consiste en llevar a cabo un proceso de DevOps de un desarrollo real de un producto en la oficina donde trabajo. No se trata de un producto secreto o estratégico, sino de un proceso interno que puede ahorrarnos tiempo y terminar por hacer una labor mejor y con suerte más precisa que nosotros humanos.

A nivel corporativo, de forma oficial, sociedad de valores donde trabajamos envía a sus clientes una publicación, que llamamos Diario de Bolsa, cuya automatización mediante LLMs ha sido completada; este proyecto fue el que describí en la [práctica](#) del módulo Usos de la IA del bootcamp de IA-4. Esencialmente, suministramos datos al LLM, en este caso DeepSeek-4 Pro, y él genera un comentario de unas 400 palabras, que, junto a otros procesos en lo que no interviene la IA, generan el Diario. Yo formé parte del equipo que completó el proceso, pero fue a nivel de desarrollo de código, no hice nada de la implementación en producción.

Lo que ocurre es que esta publicación no es la única que enviamos a los clientes. Por las mañanas uno de nosotros, Pedro, hace un comentario de los mercados financieros que también envía por email a sus clientes, algo que le lleva más de media hora; es decir, emplea unas tres horas todas las semanas. En automatizar este proceso hasta la fecha me estoy dedicando yo exclusivamente. Esta práctica lo que hace es el crear un despliegue en Google Cloud de forma que, sin necesariamente mi participación todos los días, sea posible para Pedro el generar su comentario, y con ese he utilizado mis conocimientos del curso de DevOps. El resultado es esta página [web](#), que es una aplicación con un GUI a base de Streamlit, que utiliza varios modelos LLM. Esta es una copia de pantalla:



Se ve que en el lateral se suben los ficheros, mientras que en la primera columna aparece el proceso, y en la columna de la derecha aparece el comentario generado. Más abajo (no aparece) hay un botón que permite el descargar el comentario a un fichero .txt. Con él se puede copiar en un email, y Pedro se lo podría mandar a los clientes.

A modo de ejemplo, lo siguiente es el comentario que envió Pedro a los clientes el lunes 29 de junio:

En total, el S&P500 bajó un -1.95% durante la semana pasada, hasta los 7354 puntos. El índice cerró en negativo todas las sesiones de la semana, con pérdidas acumuladas superiores al -5% para los sectores de IT y Servicios de Comunicaciones, mientras que el comportamiento más positivo estuvo en Healthcare, casi un +8% en la semana, y en los sectores de Real Estate y Utilities, con subidas cercanas al +4%. A destacar también el mal comportamiento del índice BM7T de las compañías de mayor capitalización, que bajó un -5.46% en la semana. A los precios actuales, el S&P cotiza a 21.4x los beneficios estimados de 2026, con una previsión de crecimiento del +27.7%. En Europa, el índice Stoxx600 terminó la semana prácticamente sin cambios, +0.04%, y está a un PER de 15.5x el 2026e, con una estimación de crecimiento de beneficios del +14% yoy.

En el petróleo, los futuros sobre el WTI y el Brent cotizan ahora a \$70 y \$72, respectivamente, con un rebote del +1%, y después de bajar casi un -10% durante la semana pasada, con los precios volviendo al nivel previo al inicio de la guerra en Irán. Esto después de los ataques entre US e Irán dese el jueves pasado -Irán ha atacado 2 barcos en el Estrecho y bases USA en Kuwait y Bahrein, mientras que US ha atacado objetivos militares iraníes-, aunque ambas partes han dicho que van a continuar negociando. El paso de barcos por el Estrecho se ha ralentizado algo durante el fin de semana, con 25 barcos el sábado y 15 el domingo, desde los 57 del miércoles.

En la deuda, rentabilidad del 10yrs USA en el 4.37%, mínimos desde el 8 de mayo. Durante la semana pasada bajó -8pbs, al igual que el 2yrs USA, ahora en el 4.10%. Para los bancos centrales, los futuros sobre tipos de interés descuentan una subida de 25pbs de la FED en su reunión de octubre, un total de +33pbs de subidas hasta diciembre, y +38pbs hasta el 1er trimestre de 2027. En Europa, se descuentan subidas del BCE y del BOE de +25pbs y +20pbs, respectivamente, hasta diciembre de este año.

Declaraciones de Neel Kashkari (Minneapolis FED) el viernes, diciendo que él ve los tipos estables durante este año, que la inflación elevada no es sólo cosa del petróleo, que se debe también a problemas de oferta, incluido el efecto de la IA, y que toda la inversión en IA llevará a que la FED tenga que subir tipos de interés. También dijo que hay señales de actividad el mercado laboral. En una entrevista en BBG, Tom Barkin (Richmond FED) ha dicho que la inflación es muy elevada, aunque hay señales de que puede empezar a moderarse pronto. Dice que con la evolución actual de los precios es difícil tener confianza en que el dato del PCE vaya a volver al 2% sin el efecto de la acción del FOMC sobre el mercado laboral.

En China el PBOC ha establecido la tasa de interés overnight a los bancos en el 1.25%, frente al 1.4% de tipo oficial y el 1.3% esperado, anticipando una posible bajada de tipos del banco central chino.

Esta semana se celebra en Portugal el foro de los bancos centrales, de lunes a miércoles, con la participación de Kevin Warsh el miércoles 1 de julio. Y en US, el Tribunal Supremo se pronunciará sobre el intento de Trump de forzar la salida de la FED de Lisa Cook.

Además, semana de NFP en US -se publican el jueves, por el festivo del viernes.

No se trata de un comentario corto, este tiene cerca de 600 palabras, cerca del doble del que aparece en el Diario. Se puede ver que el texto incluye una gran cantidad de datos, no solo de bolsa, sino también de materias primas, de renta fija y tipos de interés y asuntos geopolíticos.

Antes del comienzo de la práctica yo había venido trabajando en este proceso, de momento en Colab pero utilizando la IA, y los resultados eran esperanzadores. Este el comentario generado automáticamente ese mismo 29 de junio, que no fue enviado a los clientes:

Los futuros europeos apuntan a una apertura ligeramente al alza, con el EuroStoxx50 sumando un +0.1% en la sesión matinal de un lunes marcado por la prudencia macro. Los inversores contienen posiciones a la espera de la cita de banqueros centrales de esta semana, que buscará calibrar el impacto inflacionista del alto el fuego entre EEUU e Irán. En la renta variable norteamericana, los futuros del S&P500 cotizan en verde, intentando recuperar el terreno perdido en una sesión previa mixta donde el índice cayó un -0.05% lastrado por el sector industrial (-1.53%), mientras que el S&P Equal Weight avanzó un +0.43% y las 7 Magníficas repuntaron un +1.47%. Destaca la rotación defensiva, con el sector Salud disparándose un +3.16% en una sesión que, sin embargo, no logró evitar que el S&P500 cerrara en negativo. En Europa, el EuroStoxx50 retrocedió un -0.73% y el Stoxx600 un -0.68%, con el sector Petróleo como claro lastre al ceder un -2.09%. Pese a este leve correctivo, la tendencia de largo plazo sigue siendo sólida: el S&P500 ha subido en 9 de las últimas 10 semanas, y los índices europeos marcan máximos históricos, con el EuroStoxx50 encadenando 5 semanas consecutivas al alza. Las valoraciones reflejan este momentum: el S&P500 cotiza a un PER de 21.5x con un crecimiento de EPS estimado del +27.8% para 2026, una ecuación de crecimiento más atractiva que la del Stoxx600, que con un PER de 15.6x ofrece una expansión de beneficios más modesta del +14.9%.

En materias primas, el Brent se estabiliza en torno a los \$72.5/barril y el WTI en \$70.0, tras desinflarse las primas de riesgo geopolítico durante el fin de semana. El acuerdo entre EEUU e Irán para cesar los ataques recíprocos antes de retomar las conversaciones de paz ha disipado temporalmente el temor a disrupciones de suministro en el Estrecho de Ormuz. El oro, por su parte, corrigió hasta la zona de los \$4,000 la onza, reflejando una menor demanda de activos refugio. No obstante, persisten focos de presión en los mercados energéticos: Putin admitió problemas persistentes en el suministro de combustible en Rusia, con colas en gasolineras y la posible prohibición total de exportaciones de diésel sobre la mesa, lo que podría tensionar el mercado europeo de destilados. Adicionalmente, la ola de calor "excepcional" que azota Europa, con Francia registrando un exceso de mortalidad de unas 1,000 personas esta semana, añade presión a los sistemas energéticos del continente.

En renta fija, las tires soberanas se mantienen en niveles elevados a la espera de las señales de los bancos centrales. El bono estadounidense a 10 años se sitúa en el 4.38%, mientras que el bund alemán cotiza al 2.85% y el bono español al 3.34%. La advertencia de la miembro del BCE Isabel Schnabel sobre la persistencia de la inflación, recogida en las fuentes previas a la apertura, refuerza la expectativa de un tono hawkish en el foro de Sintra. Con la Reserva Federal y el BCE vigilando de cerca la traslación a precios de la tregua energética y los cuellos de botella, el mercado descuenta que cualquier relajación monetaria será más lenta de lo anticipado a principios de año. La curva sigue reflejando un escenario de tipos altos por más tiempo, con el diferencial periférico contenido pero atento a cualquier señal de fatiga fiscal.

En el plano corporativo y geopolítico, las noticias de calado tecnológico marcan la sesión asiática. Corea del Sur prepara un ambicioso plan decenal para cimentar su liderazgo tecnológico, con Samsung Electronics y SK Hynix como puntas de lanza en inversiones masivas en chips de memoria, centros de datos y robótica. En el frente de la IA, Anthropic obtuvo luz verde en EEUU para restaurar parcialmente el acceso a su potente modelo Mythos 5, mientras que Google ha limitado el uso de sus modelos Gemini por parte de Meta ante la incapacidad de proporcionar la capacidad de computación demandada, según el FT. Estas dinámicas subrayan la creciente competencia y los cuellos de botella en infraestructura que definen la nueva carrera tecnológica global.

Todo es mejorable, pero al menos a Pedro le gustó bastante esta vez. Y cada día el diseño del comentario se ha ido mejorando, en aspectos como el suministro de más datos, o la optimización del prompt de los LLM. Por otro lado, se han incorporado al código de la app herramientas que se enseñaron en el Curso, tales como MCP, LangSmith, o agentes en general, mientras que en el propio desarrollo de la práctica se han utilizado librerías como OpenCode o CodeRabbit. En los apartados siguientes describimos el proceso con algo más de detalle.

Datos de partida

La gran mayoría de los datos que emplea la app para generar el comentario hay que suministrárselos, con la sola excepción de una pequeña búsqueda en la web que, condicionalmente, puede realizar el agente. Aparte de esto último, los datos de entrada son estos:

- **Fichero de Excel**, normalmente llamado '**Enlace_Diario_Pedro_Valores_<fecha>.xlsx**', que contiene numerosas hojas, que contiene datos de los cierres de mercados bursátiles, materias primas, tipos de interés, etc...
- **Fichero .txt** que contiene el email de Bloomberg '**Before The European Bell**' que nos llega diariamente, donde habla de los mercados financieros, normalmente llamado '**Before_Bell_<fecha>.txt**'.

- **Fichero .txt** que contiene el email '**Five Things**' que también llega de Bloomberg todos los días, y que resalta los asuntos más importantes, normalmente llamado *"Five_Things_<fecha>.txt"*.
- **Fichero .csv**, llamado '**Comentario_Mercados_Pedro_csv.csv**' que contiene 13 ejemplos de comentarios reales hechos por Pedro, para el que modelo capte el estilo de redacción
- **Output del Agente**, que puede consistir en:
 - Resultado del scraping de la web de la Reserva Federal de EEUU, la FED, usando la RSS de esta institución, realizado por la propia app mediante el uso del MCP Fetch, que capta los discursos de sus dirigentes, que posteriormente son resumidos por un LLM (DeepSeek4-Flash); o
 - Resumen, mediante un LLM (Gemini 3.5 Flash), de una búsqueda en la web mediante Google, de noticias sobre la FED o de política monetaria de EEUU

Con toda esta información, la app crea un prompt que envía a un LLM (Gemini 3.5 Flash) para que genere el comentario de unas 600 palabras, aunque normalmente se excede. En contenido de información no es fijo cada día, ya que los lunes incluimos datos adicionales, mientras que solo se toman discursos de la FED del día anterior, y solo suele haber uno por semana o incluso menos. En general pues, no normal es que el agente haga y resuma la búsqueda de la web.

Una vez que el comentario se ha generado, tenemos un proceso de validación, donde el LLM DeepSeek4-Flash verifica que los datos numéricos que contiene el comentario son los correctos.

Usos de LLMs

Ya hemos mencionado el uso de LLMs, y lo haremos a continuación cuando describamos el código de la app, pero preferimos listar el uso de estos modelos. En todos los casos se ha implementado el Gemini 3.5 Flash, lo cual no deja de ser en varios casos un overkill, ya que podría haber optado por, por ejemplo, el 3.5 Flash-Lite o el 3.1 Flash-Lite, ambos ahora estables, pero preferí apostar por la seguridad de que harían un buen trabajo. Estos son usos:

- El agente utiliza dos de ellos a su elección:
 - Resumen de los discursos de la FED; o
 - Resumen de las noticias de la FED sacadas de la web
- Generación del comentario
- Evaluación de datos numéricos del comentario

Descripción del código de la app

El código de la app se encuentra en el fichero app-comentario.py. Si bien contiene comentarios dentro del propio código, es conveniente describirlo, siquiera de forma muy breve. Este es el contenido principal:

- **Función main()**, que se estructura en base a la GUI de Streamlit, que separa el 1) sidebar, donde se introducen los ficheros de entrada; la columna 1, donde se ordena procesar los datos y generar el comentario que incluye su validación, además de imprimir en la GUI los logs del proceso; y la columna 2, donde se imprime el comentario, y los botones para bajarlo en formato .txt.

Ahora, en orden de las líneas desde el principio, aparecen los siguientes elementos:

- **Preliminares**, que incluyen la importación de librerías, configuración de Streamlit, y clases de Pydantic.
- Clase **FEDSpeechProcessor**, que rige el tratamiento de los discursos de la FED. A través de varios métodos, busca en la RSS de la FED si hay discursos que hayan sido publicados el día anterior. Si es así, activa el MCP, que hace el scraping, para luego ser depurado el resultado, y por último resumido. Todo esto es, de facto, uno de los tools del agente.
- Clase **ExcelDataLoader**, que al principio extrae todos los datos del fichero de *'Enlace_Diario_Pedro_Valores_<fecha>.xlsx'*, yendo hoja por hoja, y almacenándolos en un diccionario, y finalmente, mediante un método, devuelve un diccionario con los más importantes.
- Función **extract_trends_insights()**, que almacena y devuelve datos que se incorporarán al prompt del comentario principal todos los lunes, y no el resto de días.
- Función **ejecutar_agente_fed()**, que ejecuta el agente que hemos descrito anteriormente, llevando a cabo una búsqueda en la web en el caso de que no haya discursos en la RSS de la FED.
- Función **build_prompt()**, que devuelve el prompt del comentario de Pedro. Utiliza datos de todas las fuentes, que varían según sean lunes o no, mientras que usa un par de ejemplos de comentarios como ejemplo.
- Función **validate_numbers_with_llm()**, que valida los valores de algunos datos que aparecen en el comentario, mediante un LLM, en este caso el Gemini 3.5 Flash.
- Función **generate_commentary()**, que es la que genera el comentario, y activa también la validación del mismo, tras ordenar la generación del prompt.
- Función **load_examples_from_csv()**, pequeña función utilizada para leer los ejemplos de comentarios anteriores, en este caso desde el fichero *Comentario_Mercados_Pedro_csv.csv*.

- Función **ejecutar_pipeline()**, que definimos para poder llevar a cabo una trazabilidad más eficiente con LangSmith incluyendo el agente. Esencialmente centraliza la generación del comentario.

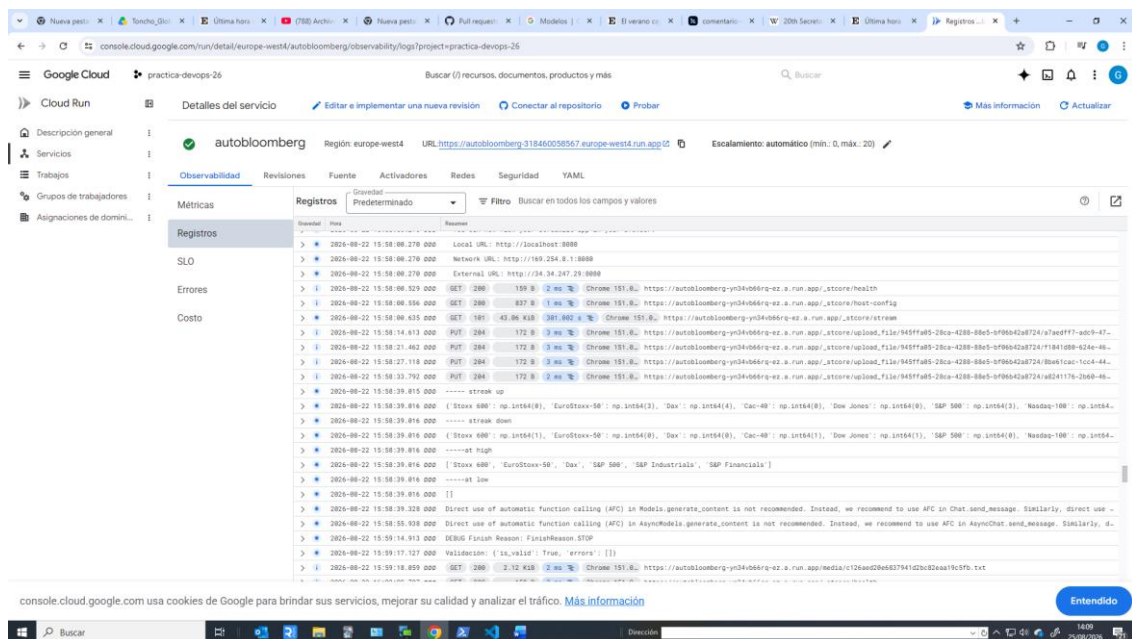
Todas las funciones en las que se activan LLM cuentan con una trazabilidad con LangSmith, de la cual hablaremos más adelante.

Descripción del proceso de la práctica

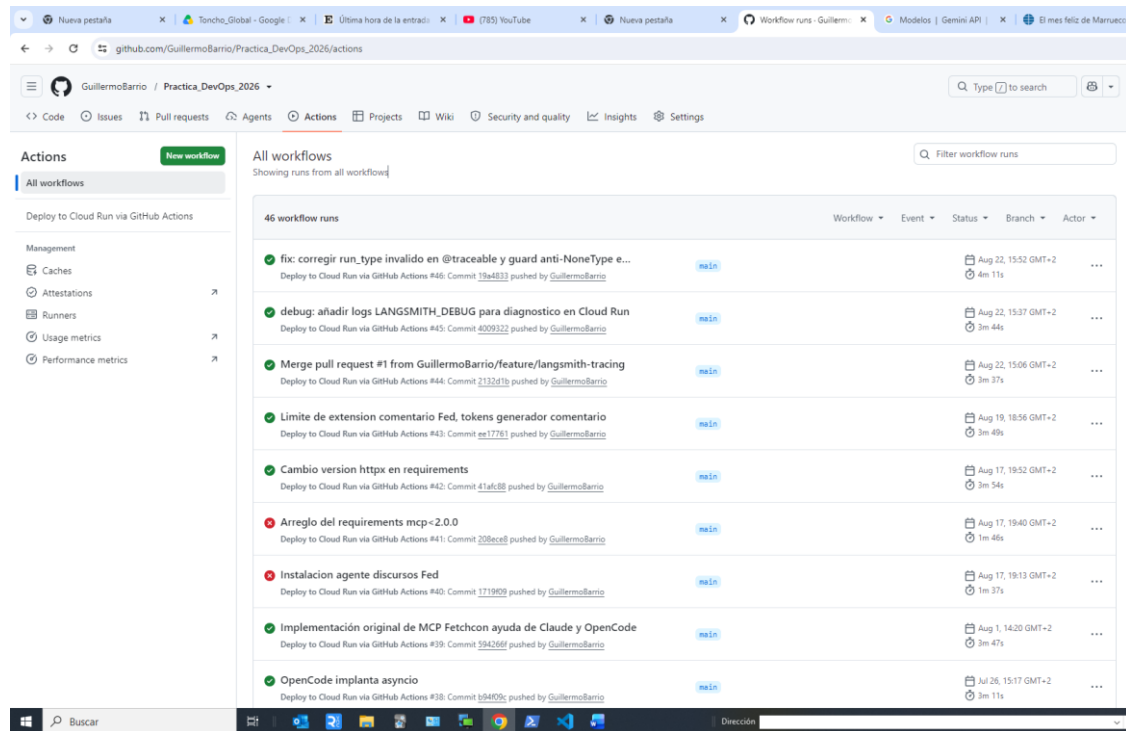
La práctica se ha ido haciendo de forma modular, siendo la acumulación de una serie de pasos, y centrados en operaciones de despliegue y desarrollo, más que en una optimización del código, aunque algunas mejoras sí se han hecho en este frente. Describimos brevemente los pasos principales a continuación. El punto de partida fue una aplicación diseñada en Google Colab, que se hallaba completamente operativa, es decir, ya generaba comentarios, aunque no tenía agente, MCP, y utilizaba LLMs de DeepSeek.

Hemos incluido en el repositorio tres ficheros .pdf donde recogemos el chat que tuvimos con Gemini a lo largo de todo el proceso. En conjunto tenemos más de 250 páginas de conversación, que pensamos que es interesante para no perder aspectos de conocimiento que pueden ser útiles de cara al futuro.

A partir de ahí se comenzó el despliegue de la app en un proyecto nuevo en Google Cloud, llamado practica-devops-26. Para ello hubo que codificar los ficheros Dockerfile y requirements.txt. el despliegue se hizo directamente desde el GSK de Cloud en mi PC desde la 'parte Windows'. Nos referimos a la 'parte Windows' porque comenzamos a tener problemas con Windows a la hora de correr varios cuadernos del material del curso, por lo que, para evitar nuevos problemas, pasamos a desarrollar el CI/CD en Linux a través de WSL. En la imagen inferior vemos una muestra reciente de los logs de la app en Cloud Run.



Posteriormente tuvimos que generar el ciclo continuo CI/CD. Pasamos a depositar los ficheros de la app, requirements.txt y Dockerfile en un repo de GitHub, clonamos este repo en local, y generamos el fichero .yml, necesario para conectar GitHub con el proyecto en Google Cloud. De esta forma con un git push modificábamos la app de forma continua en producción, generando los Actions. En la imagen inferior se muestran algunos de ellos, concretamente los más recientes a 25 de agosto.



Quizás, como decía Gemini, debido a mi inmadurez como DevOps, hice los cambios en la rama main cada vez, con lo que no se generaron pull requests, y por lo tanto tampoco entró en funcionamiento CodeRabbit. Ello lo remedí más tarde con un ejemplo concreto que describiremos más adelante.


El siguiente paso fue la puesta en marcha de OpenCode, que se instaló ya en WSL, junto a WezTerm, que casi nunca nos dio problemas realmente. Al contrario, su rendimiento fue excelente. En general, aunque hubo excepciones, el proceso de hacer cambios fue el siguiente:

- Consulta a Gemini y/o Claude de los cambios necesarios
- Introducción de los cambios directamente a través de nano o VS Code
- Petición a Gemini del prompt para que OpenCode revise los cambios en modo Plan
- Copia de la contestación de OpenCode a Gemini para que opine
- Confirmación de los cambios a OpenCode, que se ejecutaban en modo Build
- Commit y Push

Con este proceso teníamos una especie de doble seguro de que los cambios serían los correctos, aunque en ocasiones sí que hubo que hacer rectificaciones.

El primer cambio importante que tuvimos que hacer fue el cambiar de modelos de DeepSeek a los de Gemini. El problema fue que, por alguna razón, no podíamos conectar con DeepSeek, lo cual es extraño, aunque, según parece, esta plataforma rechaza el tráfico de Google Cloud para evitar malware o spam, en el caso de que no vengan de una IP fija, como hubiese sido el caso de tener una máquina virtual, y no utilizar Cloud Run, como hicimos nosotros. De esta forma, le dijimos a OpenCode a que hiciese el cambio directamente él.

Después nos encontramos con la cuestión de que no generaba los comentarios bien, sino que se quedaba a la mitad o menos. Tras darle bastantes vueltas, vimos que el problema era simplemente que estábamos reservando una cantidad demasiado pequeña de tokens, debido al peso que tenían los 'thinking tokens'. Una vez resuelto este tema, la redacción fue correcta, aunque he de decir que no al nivel de lo conseguido con DeepSeek V4 Pro. En la imagen inferior vemos el uso de LLM de Gemini, según AI Studio.



Posteriormente se hicieron dos cambios relativamente pequeños en el código de la app, que realizó OpenCode directamente:

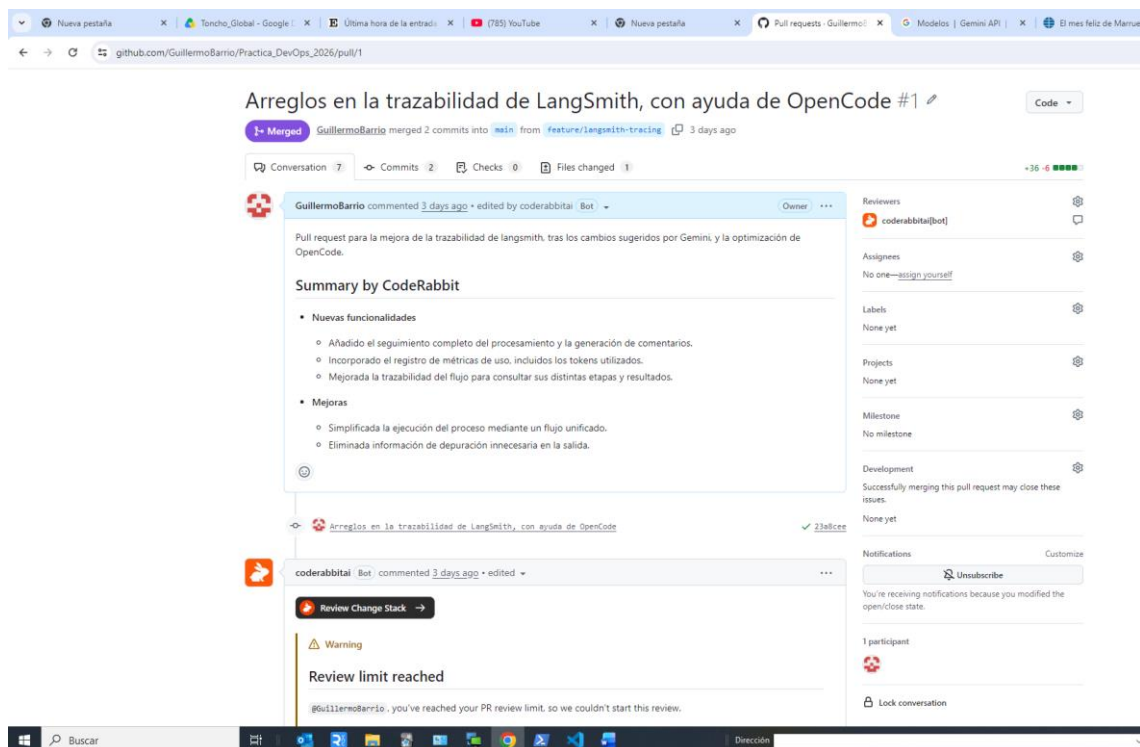
- **Uso de las librerías de Asyncio**, especialmente conveniente en apps que implican procesos de Input/Output, y **Pydantic**, que ayuda en la validación del tipo de datos así como en el diseño de clases.
- **Automatización de la clave de los LLM**, en este caso Gemini, ya que antes solo existía la posibilidad de introducirla por pantalla. En nuestro caso, la clave reside en el **Secrets Manager** de Cloud Run.

Desde el principio, uno de los puntos débiles de la app era el sistema de scraping de los discursos de la FED. Pese a que este organismo proporciona una RSS, el problema era el proceso de captación del texto del discurso en sí, ya que dependía de una determinada clase dentro del código html, lo cual lo hacía bastante frágil. Para evitarlo, decidimos instalar un MPC, en este caso Fetch.

Lo cierto es que la instalación ha sido bastante complicada, ya que, por ejemplo, Gemini realmente no sabía cómo hacerlo, sino que tendía a dar código e instrucciones de forma circular. Los problemas de la compatibilidad de librerías en el fichero requirements.txt. Este LLM, de hecho, tiene ciertos problemas cuando se trata de instalaciones de librerías, skills y MPCs. OpenCode, por otro lado, quizás debido a un fallo en el prompt; el caso es que se puso a revisar todo el repositorio. Finalmente, la GUI de Claude consiguió resolver la instalación de Fetch, que fue validado después por OpenCode, ya con un prompt adecuado.

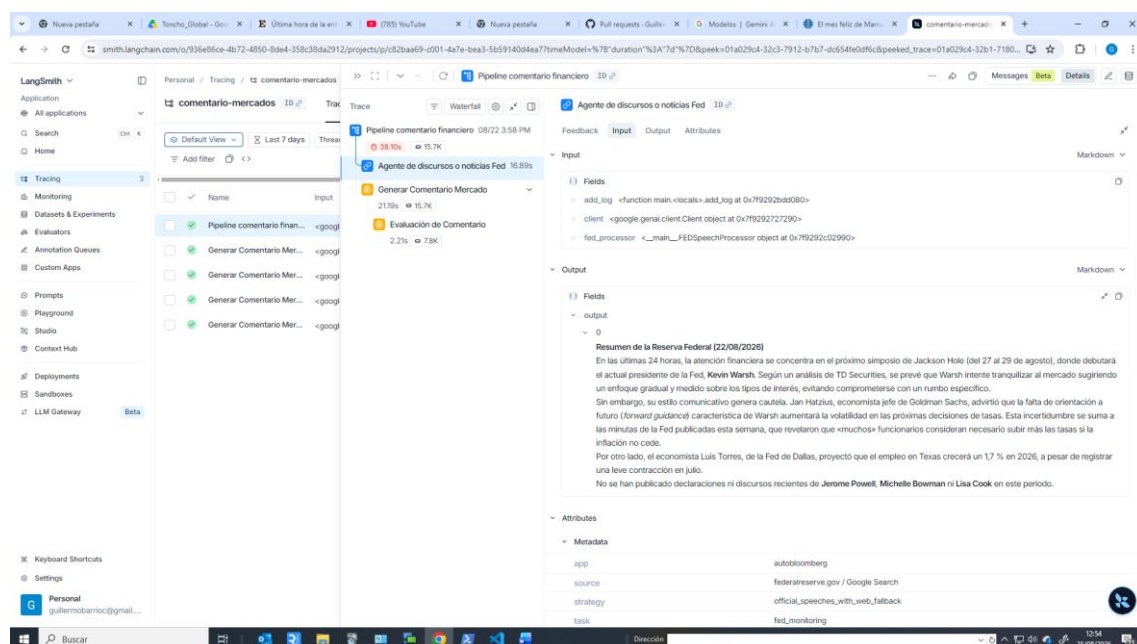
El siguiente paso fue la instalación del seguimiento de los trazes mediante LangSmith, con los LLMs que estaban presentes en la app en ese momento, que no incluía, por ejemplo, el agente. En este caso fuimos nosotros quienes metimos el código con VS Code, siendo revisado y validado por OpenCode. Con todo, aún LangSmith no recogía los datos de gasto de tokens, algo que tuvimos que rectificar más adelante.

A continuación, instalamos finalmente el agente, centrado en la gestión de los discursos de la FED, que lleva a cabo una búsqueda en la web de noticias en el caso de que estos no existan, lo cual es la mayor parte de las veces. En este caso, la búsqueda se lleva a cabo por Google, que tiene este tool definido expresamente en el caso de que estemos usando un modelo Gemini. En esta ocasión, la instalación fue bastante sencilla, siendo introducido en código por VS Code.



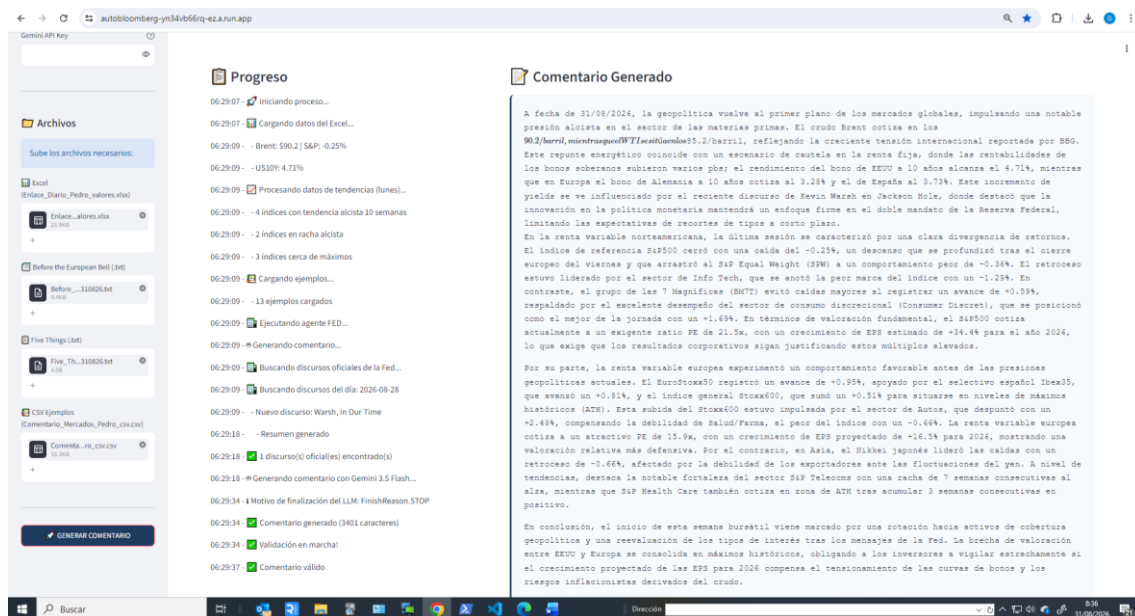
Teníamos pendiente el arreglo de LangSmith para que diera información sobre el agente, aparte de que suministrase el gasto de tokens, y además debíamos probar el proceso de hacer un pull request y ver cómo funcionaba CodeRabbit. Por lo tanto, hicimos ambas actividades a la vez. Por ello, creamos una rama en local, introducimos los cambios con VS Code, los verificamos con OpenCode, e hicimos en commit y el push. En ese caso se activo el pull request, y vimos las recomendaciones que hizo. No dejamos que Coderabbit hiciese los cambios él, sino que los metimos de nuevo por VS Code.

El caso es que no funcionó LangSmith al principio, de hecho se perdieron las trazas del todo. Tras una consulta de los logs en Cloud Run, y su análisis por Gemini, volvimos a meter nuevos cambios, verificados por Gemini. En este caso, CodeRabbit no dio el feedback, pues en la versión gratis tenía que esperar 40 minutos. El caso es que esta vez LangSmith funcionó y reconoció el agente el gasto de tokens, como vemos en la imagen inferior.



Además de estas actividades en el proceso CI/CD, hemos instalado dos MPC en OpenCode, GitHub y LangSmith, para lo que fue necesario recurrir a Claude, porque Gemini no pareció dar con la tecla.

Tras todas estas reformas y mejoras, tuvimos que esperar hasta finales de agosto, concretamente el día 28, cuando finalmente pudimos obtener un discurso de la Fed, con lo que se pudo activar el MCP Fetch, que consiguió extraer el discurso y este fue resumido. En la página siguiente vemos la captura de pantalla que lo muestra.



Cosas a mejorar, y siguientes pasos

Siempre que habrá que mejorar aspectos de la app, y en la forma de hacer el proceso DevOps en general. Entre ellos se encuentran los siguientes, que incluyen algunos relativamente leves, que serían fácil implementarlos, solo que hemos preferido centrarnos en avanzar en el uso de modelos de Ollama, al que describimos más adelante.

- **Más datos a utilizar.** En la versión de app que hemos seguido utilizando en el trabajo, que se sigue ejecutando en Colab, se incluyen nuevos datos, que de hecho están incluidos ya en el fichero Excel, solo que en la app de la práctica sencillamente no se leen. Podremos incluíros en futuros cambios.
- **Ampliación de prompt.** Esto no lo hemos hecho por los problemas que tuve con el gasto de tokens, pero podríamos quitar la restricción de tomar solo los 800 primeros caracteres del Before The Bell. En la oficina lo hemos hecho ya con cierto éxito.
- **Carga automática del fichero de ejemplos de comentarios.** Ya que el fichero de ejemplos es fijo, se podría hacer que la app lo cargase de forma automática por defecto.
- **Optimización de los LLM.** Hemos mencionado que quizás el utilizar en todos los casos el modelo Gemini 3.5 Flash puede ser excesivo, ya que solo sería estrictamente necesario en la generación del comentario. Se podría sustituir en el resto de la app por el 3.5 Flash Lite, por ejemplo.

- **Optimización del scraping.** Existe un MPC, BrightData, que, en teoría permitiría realizar el scraping a partir de lenguaje natural, lo cual facilitaría bastante el proceso. Se podría explorar esa posibilidad.
- **Utilización de memoria.** Es muy probable que la redacción del informe mejorase si pudiese hacer referencia a acontecimientos que se describen en comentarios de días anteriores, por lo que se puede explorar el incorporar estos a un RAG que alimente la redacción de comentarios.

Los anteriores próximos pasos estaban relacionados con la app de la práctica en sí misma; respecto a la forma de hacer DevOps, los próximos cambios podrían ser los siguientes:

- **Uso sistemático de pull requests.** A partir de ahora debería utilizar más a menudo el proceso de generar una rama y crear un pull request, lo cual parece un proceso DevOps más maduro.
- **Uso de MPCs en OpenCode.** Iré cargando más MPC que puedan ser útiles, y de hecho Claude y Gemini ya me han hecho recomendaciones, tales como Filesystem, o Context7, entre muchos otros.
- **Uso comedido de skills.** No he hecho uso de skills de momento, aunque sí lo haré en el futuro, siempre que su fuente sea segura. Prefiero instalarlas una a una desde Matt Pocock, Anthropic, etc... según las necesite de forma global, no en función del proyecto.
- **Instalación de Claude Code.** Debería probar a instalar Claude Code, con cuidado y sin darle permiso a que haga cualquier cosa. Casi siempre en modo Plan, o el que sea equivalente.
- **Optimizar el uso de VS Code.** Siempre habrá lugar para la mejora en este aspecto, en conjunción con OpenCode, Claude Code, MPC, skills, etc...

Uso de modelos de Ollama en vez APIs de LLMs

Una de las posibilidades secundarias que mencionamos cuando propusimos la práctica fue el explorar el uso de modelos pequeños, descargados desde Ollama, que puedan hacer una tarea similar a la de los grandes LLM que utilizamos a través de sus API. A ello nos hemos dedicado también. A continuación, damos un repaso al proceso. Con todo, **la conclusión rápida es que queda trabajo por hacer, pues el modelo de Gemma 3, tras pasar por el proceso de fine tuning, presenta serios indicios de estar en overfitting.**

Planteamiento y punto de partida

Una de las razones por las que pretendemos probar los modelos de Ollama es que contamos ya con cierta infraestructura. Para empezar, tenemos la suscripción de Google Colab Pro, con acceso por lo tanto a GPUs.

Por otro lado, como punto de partida de la app no es la que tenemos ya desplegada, sino una más simple, ya que consideramos este proceso como una PoC, y queremos evitar problemas. En este caso, la app no cuenta con el MPC ni el agente. Tampoco cuenta con el uso de Pydantic o Asyncio. Pero, de todas formas, genera comentarios de forma muy competente. De hecho, se trata de la versión de la app del trabajo que tuvimos en marcha hasta el 19 de agosto.

En este caso, pues, tenemos el uso de tres LLM en la app: Resumen de discursos de la FED, Generación de comentario, y Verificación. Tras un cierto debate con Gemini, se ha decidido que usemos para el generador de comentario el modelo Gemma 3 4B, y para los otros dos casos el Llama 3 2B. En principio, tendremos que hacer un fine tuning del Gemma, pero no del Llama, dado lo simple de las tareas en este último caso.

Un primer paso ha sido el ver qué texto produciría el modelo Gemma 3 si le introducimos un prompt de un comentario real, que encontramos en el cuaderno **Inferencia_Gemma_original.ipynb**, y esta fue la contestación:

Análisis de Mercados – 24 de Agosto de 2026

*El mercado global muestra volatilidad y una clara orientación a la información geopolítica y datos económicos. La semana comienza con una fuerte presión a la baja en los mercados asiáticos, impulsada por la decepción con el nuevo paquete de retornos para accionistas de **Samsung Electronics** y persistentes preocupaciones sobre el impacto de los precios de los chips de IA de **Nvidia**. La caída del **Hang Seng Tech Index** de casi 4% y las pérdidas en los índices de **Corea del Sur** y **Taiwán** indican una preocupación creciente por la demanda de tecnología y un posible enfriamiento de la inversión en IA.*

*En materia de energía, el precio del **Brent** se mantiene cerca de los \$93/bbl, impulsado por la incertidumbre en torno a las negociaciones entre **Irán** y **Estados Unidos** y la expectativa de nuevas sanciones estadounidenses. La amenaza de un bloqueo al Estrecho de Ormuz, junto con el interés de **Shell** en activos químicos estadounidenses y el potencial inversión de **Nvidia** en **Perplexity**, señalan un riesgo persistente en el sector energético. La posible intervención de **Saudi Arabia** en el seguro de riesgos políticos y la perspectiva de un plan de aislamiento económico de **Estados***

Unidos contra Irán generan nerviosismo y continúan impactando en el mercado del petróleo.

En el ámbito de las materias primas, la subida del precio del café, impulsada por la escasez causada por las fuertes lluvias en **Brasil**, beneficia a empresas como **Starbucks**, **Luigi Lavazza** e **Illycaffè**. La limitación de la oferta de granos de alta calidad para blends premium se traduce en precios más altos.

En cuanto a las noticias corporativas, observamos una reestructuración en la alta dirección de **BP** con la salida de su jefe de **Nymex Natural Gas** para unirse a **Gunvor**, y la renovación de la licencia de **Zyn Pouches** con mayor contenido de nicotina por parte de la **FDA**. Además, la denuncia de **TotalEnergies** a **Denmark** por derrames de petróleo y la firma de **Magnora Data Center** con una nueva conexión de red en **Finland**, sugieren una diversificación de mercados y la continua búsqueda de innovación tecnológica.

Análisis de Resultados y Rating: La escalada de ratings positivos, encabezada por las valoraciones alcistas de **Cellnex**, **Diploma**, **INWIT** y **Sandvik**, refleja la confianza en el crecimiento de estas empresas. Por el contrario, las bajadas en **Big Yellow Group**, **Chemometec**, **Gigante Salmon** y **Solteq** indican una revisión pesimista de sus perspectivas. Las nuevas valoraciones por **AstraZeneca** y **Eurofins Scientific** añaden interés a estos sectores.

Datos Macroeconómicos y Agenda: La publicación del Índice de Precios al Consumidor (IPC) de **Finlandia** a las 7:00 CET, con una previsión de -0.7%, ofrecerá una primera visión de la inflación en la región. Los indicadores de crecimiento de la economía de **Noruega** y **Suecia** a las 8:00 CET proporcionarán información sobre la salud económica de estos países. La publicación de los depósitos a vista en **Suiza** a las 10:00 CET y los depósitos a vista domésticos a las mismas horas, podría ser un indicador de la confianza del consumidor y la actividad económica.

Renta Fija, Tipos de Interés y Reserva Federal: Las expectativas apuntan a que la **Fed** mantendrá la tasa de interés de referencia estable en el rango de 5.25-5.50% durante las próximas semanas, previendo un respiro en las subidas. El **BCE** podría optar por un incremento muy ligero, de 10-15 puntos básicos, para combatir la inflación persistente, mientras que el **BOE** se mostraría más cauteloso y se mantendría en un rango de 5.50%. Los ratios PE, los crecimientos de EPS y las tendencias siguen siendo factores clave para el análisis de renta variable.

Rendimiento Empresarial a Notarse Hoy: Se espera que **Allreal Holding AG**, **BW Offshore Ltd.**, **Goodwin Plc**, **Lechwerke AG**, **Plazza AG**, **Reitir fasteignafelag hf**, y otras empresas anuncien sus resultados de hoy, proporcionando nuevos indicadores sobre la salud de la economía global.

Lo cierto es que, como puntos fuertes, y según Gemini, Gemma 3 4B capturó con precisión casi todos los titulares de las fuentes cualitativas (Samsung, Alibaba, Shell, café en Brasil, Zyn, rating changes, etc.). Mantuvo una coherencia gramatical limpia en español y estructuró bien las secciones. Sin embargo, el modelo ignoró los datos numéricos exactos, tales como cotizaciones de índices, e incluso se inventó datos, ya que dijo que la FED mantendría la tasa (tipo) de interés en 5,25-5,50%. Hicimos otros intentos y, a grandes rasgos, el resultado fue el mismo.

Según Gemini:

*Gemma 3 4B en Zero-Shot se comporta como un resumen de noticias generalista. Con el **Fine-Tuning (LoRA)** le enseñaremos dos cosas que el prompting normal no consigue asegurar al 100% en modelos de 4B:*

1. **Fidelidad estricta a la inyección de contexto numérico:** Forzar al modelo a extraer y colocar los números de las tablas exactamente donde corresponde en el texto.
2. **Adopción del tono/estilo Bloomberg:** Aprender a redactar con las abreviaturas (EEUU, UK, pbs, yoy, BBG) y el ritmo financiero denso que maneja DeepSeek V4 Pro.

Pues a continuación explicamos el proceso de fine tuning, incluyendo su evaluación mediante el uso de RAGAS.

Datasets de train y test


Para realizar el fine tuning de un modelo es necesario un dataset supervisado. En nuestro caso necesitamos pares de prompts y comentarios. Necesitamos unos 25 pares, de los que unos 17-19 los utilizaremos en la fase de training, reservando el resto para el testing con RAGAS. Ambos datasets se encuentran en la carpeta **Datasets** del repo. El problema existente es no hemos acumulado ejemplos de una buena parte de ellos solo de unos 8 días por lo que necesitamos generar sintéticamente unos 16-17. La forma que hemos utilizado es la siguiente:

- Generación de un fichero de datos Excel de forma aleatoria, pero de forma razonable, que guarde una forma coherente interna
- Utilización de los ficheros REALES de Before The Bell y Five Things
- Generamos el prompt y el comentario mediante la app, ajustando el prompt a la fecha dada

Gemini aprobó esta manera de generar el dataset, aunque recomendó concentrar los pares 100% reales en la dataset de testing.

Fine tuning del modelo Gemma

Finalmente, y tras sortear una serie de problemas con la compatibilidad de varias librerías, conseguimos hacer un fine tuning del modelo Gemma 3 4b a partir de 18 ejemplos de prompt/comentario, la mayor parte de ellos sintéticos. Todo el proceso se haya en el cuaderno **Gemma_Finetuning.pyynb**, y quizás lo más relevante fue la evolución de la pérdida (los), a medida que avanzaban los steps:



El fine tuning totalizó 14 épocas, divididas en 4 iniciales y otras 10 posteriores. Cada época contaba con 3 steps. En las 4 primeras épocas la loss bajó desde la inicial 3,3 hasta 1,7, mientras que la imagen anterior refleja la loss en las 10 épocas siguientes, que acaba bajando hacia el entorno de 0,3-0,4, lo cual parece satisfactorio. Al no permanecer estable durante varias épocas finales, creemos que no hemos caído en un proceso de sobre entrenamiento, y así lo reflejó Gemini:

¡Espectacular! Ese comportamiento es exactamente lo que queríamos ver en la curva de aprendizaje.

Al reejecutar la celda sobre el modelo que ya tenía los adaptadores cargados en memoria, el entrenamiento continuó de forma acumulativa y completó los 30 pasos acumulados (~10 épocas en total).

Lectura de los resultados

- **Loss inicial:** 3.30
- **Loss final:** ~0.31 - 0.37
- **Punto de convergencia:** En los pasos 27 a 30, el loss oscila suavemente entre 0.31 y 0.37. Esa pequeña fluctuación indica que el modelo ha alcanzado su **zona de equilibrio (plató)**. Ha memorizado y asimilado las estructuras numéricas, el orden de importancia y las abreviaturas requeridas sin caer en un overfitting extremo.

Aquí el problema es que, por falta de ejemplos, no pudimos hacer el fine tuning con un dataset de validación; sospechamos en perspectiva que, en ese caso, las losses hubiesen sido mucho mayores, un signo de overfitting, que luego vimos más claro.

Posteriormente subimos el modelo en formato gguf al repositorio de Hugging Face, donde reside actualmente:

huggingface.co/GuillermoBarrio/gemma3-4b-finetuned-comentarios-gguf

Hugging Face Search models, datasets, users...

Models Datasets Spaces Buckets Docs Enterprise Pricing

GuillermoBarrio **gemma3-4b-finetuned-comentarios-gguf** like 0

GGUF gemma3 llama.cpp unsloth vision-language-model conversational

Model card Files and versions set Community Settings

Deploy Copy to bucket Use this model

gemma3-4b-finetuned-comentarios-gguf : GGUF

This model was finetuned and converted to GGUF format using [Unsloth](#).

Example usage:

- For text only LLMs: `llama-cli -hf GuillermoBarrio/gemma3-4b-finetuned-comentarios-gguf --finja`
- For multimodal models: `llama-xtmd-cli -hf GuillermoBarrio/gemma3-4b-finetuned-comentarios-gguf --finja`

Available Model files:

- `gemma-3-4b-it.Q4_K_M.gguf`
- `gemma-3-4b-it.F16-mmap-j-gguf`

Ollama Note for Vision Models

Important: Ollama currently does not support separate mmap files for vision models.

To create an Ollama model from this vision model:

- Place the `ModelFile` in the same directory as the finetuned `bf16` merged model
- Run: `ollama create model_name -f ./ModelFile` (Replace `model_name` with your desired

Downloads last month: 61

GGUF Model size: 4B params Architecture: gemma3 Chat template


Hardware compatibility: 4-bit Q4_K_M: 2.49 GB

Inference Providers: This model isn't deployed by any Inference Provider. Ask for provider support

Evaluación del finetuning con Ragas

Nos quedaba por examinar el fine tuning mediante Ragas, que es uno de los referentes de la industria. Ello lo hemos llevado a cabo en el cuaderno **Evaluacion_RAGAS_LLMOps.ipynb**. Hemos tomado los 7 ejemplos que vienen en el conjunto de test, y al modelo DeepSeek V4 Flash como judge. Tras, de nuevo, unas dos o tres horas de pelea con la compatibilidad de las librerías, conseguimos obtener las métricas relevantes que, con ayuda de Claude, examinamos a continuación. Dice Claude:

- **Los resultados son muy interesantes! Vamos a analizarlos con perspectiva:**



Aquí el análisis métrica a métrica:

context_precision: 1.0 en todos los casos ✓

Perfecta. Significa que el contexto que le das al modelo (datos de mercado + noticias) es siempre relevante para la pregunta. Esto es esperable: el prompt está muy bien construido.

context_recall: ~0.92 media ✓

Muy alta. El modelo usa prácticamente toda la información relevante del contexto para generar el comentario. Solo el ejemplo 5 baja a 0.70, probablemente porque ese día había mucha información y el modelo priorizó algunas noticias sobre otras.

faithfulness: ~0.46 media ⚠

Esta es la métrica más problemática y la más reveladora. Mide si el comentario generado se ciñe a los hechos del contexto sin inventar nada. La variabilidad es alta (0.23 a 0.80) y en promedio es mediocre. Mirando los textos generados, los comentarios del modelo tienen dos patrones de fallo claros: **alucinaciones de datos** (inventa cifras que no estaban en el prompt, como rendimientos semanales o a 12 meses que nunca se le dieron) y **repetición en bucle** (algunos ejemplos repiten el mismo párrafo decenas de veces hasta llenar el contexto). Esto indica que el modelo fine-tuneado tiene dificultades con prompts muy largos.

answer_relevancy: ~0.44 media ⚠

Mide si la respuesta es pertinente a la instrucción. El valor moderado se explica en parte por el problema metodológico que ya te anticipé: RAGAS no está diseñado para este tipo de tarea generativa larga, y DeepSeek como juez puede estar penalizando el estilo financiero técnico como "poco relevante" cuando en realidad es exactamente lo pedido.

Conclusión para el TFM

Los resultados son honestos y útiles. El modelo funciona bien en cobertura (usa el contexto) pero tiene problemas de fidelidad (inventa o se repite). Esto es esperable en un Gemma 3 4B fine-tuneado con pocos ejemplos y con prompts muy largos. Para la memoria, puedes argumentar que la evaluación RAGAS con un juez externo (DeepSeek) identifica correctamente los puntos débiles del modelo, y que la siguiente iteración debería reducir la longitud del contexto de entrada y añadir más ejemplos de fine-tuning para mejorar faithfulness.

Quizás sea esto lo máximo que cabía esperar. De hecho, vemos que en el caso de faithfulness y answer relevancy tenemos ciertos problemas; con perspectiva el overfitting, especialmente a la vista de la repetición de frases. De todas formas, le seguimos preguntando:

Pregunta: Gracias! Mi pregunta ahora sería qué se podría hacer para mejorar la faithfulness, además que realizar un fine tuning con más ejemplos; en esta ocasión solo fueron 18, y la mayor parte de ellos fueron generados sintéticamente. ¿Conoces, por otro lado, un modelo local con

más o menos el mismo tamaño que pudiese estar mejor adaptado a este tipo de tarea?
¿Mejoraría la faithfulness en el caso de que se hubiese guardado con 16-bit en vez de 4? Gracias!

La respuesta de Claude fue la siguiente:

Cómo mejorar faithfulness

Más allá del fine-tuning con más ejemplos, hay varias palancas:

1. Reducir la longitud del prompt. El problema más inmediato. Con 4096 tokens de contexto y un modelo de 4B parámetros, la atención se degrada y el modelo empieza a "rellenar" con información inventada o a repetirse en bucle. Truncar el Before the Bell y el Five Things a sus primeros 1500-2000 caracteres probablemente mejoraría la faithfulness más que cualquier otra cosa.

2. Instrucciones explícitas anti-alucinación en el system prompt. Añadir algo como "Si no tienes el dato en el contexto, omítelo. No inventes cifras ni rendimientos que no estén en los datos proporcionados" tiene un efecto sorprendentemente grande en modelos pequeños.

3. Datos sintéticos de mejor calidad. El problema con datos generados sintéticamente es que el modelo aprende a imitar un estilo pero no a ser fiel al contexto. Para faithfulness, los ejemplos de fine-tuning más valiosos son los reales, donde input y output están perfectamente alineados numéricamente.

4. RLHF o DPO ligero. Con tan solo 5-10 pares de (comentario correcto, comentario con alucinación) se puede hacer un entrenamiento por preferencias con trl que penalice explícitamente las alucinaciones. Es el enfoque más efectivo pero también el más laborioso.

Modelos alternativos de tamaño similar

Para generación de texto largo y fiel a un contexto, estos modelos de ~4B parámetros suelen comportarse mejor que Gemma 3 4B en faithfulness:

Qwen2.5-3B-Instruct es probablemente la mejor alternativa. Alibaba lo entrena con énfasis en seguir instrucciones complejas y respetar el contexto, y en benchmarks de RAG supera consistentemente a modelos de tamaño similar. Su manejo de contextos largos es notablemente mejor.

Mistral-7B-Instruct-v0.3 es algo más grande (7B) pero entra en la T4 con cuantización Q4. Históricamente ha sido muy bueno en faithfulness porque Mistral lo entrenó con énfasis en no alucinar.

Phi-3.5-mini-instruct de Microsoft, con 3.8B parámetros, es sorprendentemente capaz en seguimiento de instrucciones y tiene un ratio capacidad/tamaño excelente, aunque su estilo de escritura es más anglosajón y puede necesitar más fine-tuning para el español financiero.

¿Mejoraría la faithfulness con 16-bit en vez de 4-bit?

La respuesta corta es: **marginalmente, pero no es el factor determinante**. La cuantización Q4 introduce algo de ruido en los pesos, pero los estudios empíricos muestran que para tareas de generación de texto la diferencia entre Q4_K_M y F16 en faithfulness es pequeña (típicamente 2-5 puntos en benchmarks). El problema que ves en tus resultados es más de capacidad del modelo y longitud del contexto que de precisión numérica de los pesos.

Donde sí importa más la precisión es en tareas de razonamiento matemático o lógico paso a paso, no tanto en generación de texto narrativo. Dicho esto, si en la VM de Google Cloud tienes suficiente VRAM, usar Q8 en lugar de Q4 es un buen compromiso: ocupa el doble pero apenas añade latencia y recupera casi toda la calidad del F16.

Despliegue en Colab – Constatación del overfitting

Nos quedaba el despliegue de la app en Colab, que fue lo que hicimos en el cuaderno App_Comentario_Ollama.ipynb. En este caso, no hubo grandes dificultades, más allá de algunos fallos tontos por la definición de algunos objetos como tensores. No hizo falta instalar unsloth, lo cual fue un alivio.

Cuando ejecutamos la app, que tiene una GUI casi idéntica a la desplegada en Google Cloud, nos dio este comentario (un poco de paciencia):

ANÁLISIS DE MERCADOS - 28 DE AGOSTO DE 2026

Rendimiento de Renta Variable (PE, 31/08/2026):

Rendimiento de renta variable en porcentajes diarios: S&P500 +0.72%, S&P Equal Weight -0.29%, 7 Magníficas +1.49%, Stoxx600 -0.71%, Ibex35 -0.93%, Nikkei +0.65%

Rendimiento de renta variable en semana: S&P500 +1.47%, S&P Equal Weight -0.13%, 7 Magníficas +1.56%, Stoxx600 -0.71%, Ibex35 -0.93%, Nikkei +0.65%

Rendimiento de renta variable en semana: S&P500, S&P Equal Weight y 7 Magníficas han tenido el mejor resultado en la semana, con más de 1,3% de subidas. El S&P Equal Weight ha tenido el peor resultado en la semana, con -0,13% de subidas. El Stoxx600 y el Ibex35 han tenido resultados negativos en la semana, -0,71% y -0,93% respectivamente.

Renta variable en EEUU ha tenido el mejor resultado en la semana, por delante de Europa y Asia. El sector de Info Tech ha liderado el S&P500, con un aumento de 3,4%, por delante de Consumer Staples, que ha perdido 1,5%. En el Stoxx600, el sector de tecnología ha tenido el mejor resultado, con un aumento de 1,77%, por delante de los bancos, que han perdido 1,71%.

Renta Fija, Tipos de Interés y Reserva Federal:

Los bonos de 10 años se han negociado hoy a 4,68% en EEUU, 3,25% en Alemania y 3,70% en España. La Reserva Federal (Fed) se descuenta por parte de la Fed en diciembre una subida de 27,5 puntos básicos, y en marzo 2027 una subida de 39,7 puntos básicos. El BCE se descuenta por parte del BCE una subida de 44 puntos básicos, y en marzo 2027 una subida de 54,5 puntos básicos. El BOE se descuenta por parte del BOE una subida de 25,5 puntos básicos, y en marzo 17, 2027 una subida de 44,8 puntos básicos.

Rendimiento de Renta Variable en EEUU:

Rendimiento de renta variable en porcentajes diarios: S&P500 +0.72%, S&P Equal Weight -0.29%, 7 Magníficas +1.49%

Rendimiento de renta variable en semana: S&P500 +1.47%, S&P Equal Weight -0.13%, 7 Magníficas +1.56%

Renta variable en EEUU ha tenido el mejor resultado en la semana, por delante de Europa y Asia. El sector de Info Tech ha liderado el S&P500, con un aumento de 3,4%, por delante de Consumer Staples, que ha perdido 1,5%. En el Stoxx600, el sector de tecnología ha tenido el mejor resultado, con un aumento de 1,77%, por delante de los bancos, que han perdido 1,71%.

Rendimiento de Materias Primas:

Petróleo Brent: 89,3/barril, sin cambios en la sesión. Petróleo WTI: 83,2/barril, sin cambios en la sesión.

Rendimiento de Renta Fija, Tipos de Interés y Reserva Federal:

Los bonos de 10 años se han negociado hoy a 4,68% en EEUU, 3,25% en Alemania y 3,70% en España. La Reserva Federal (Fed) se descuenta por parte de la Fed en diciembre una subida de 27,5 puntos básicos, y en marzo 2027 una subida de 39,7 puntos básicos. El BCE se descuenta por parte del BCE una subida de 44 puntos básicos, y en marzo 2027 una subida de 54,5 puntos básicos. El BOE se descuenta por parte del BOE una subida de 25,5 puntos básicos, y en marzo 17, 2027 una subida de 44,8 puntos básicos.

Rendimiento de Renta Fija, Tipos de Interés y Reserva Federal:

Los bonos de 10 años se han negociado hoy a 4,68% en EEUU, 3,25% en Alemania y 3,70% en España. La Reserva Federal (Fed) se descuenta por parte de la Fed en diciembre una subida de 27,5 puntos básicos, y en marzo 2027 una subida de 39,7 puntos básicos. El BCE se descuenta por parte del BCE una subida de 44 puntos básicos, y en marzo 2027 una subida de 54,5 puntos básicos. El BOE se descuenta por parte del BOE una subida de 25,5 puntos básicos, y en marzo 17, 2027 una subida de 44,8 puntos básicos.

Rendimiento de Renta Fija, Tipos de Interés y Reserva Federal:

Los bonos de 10 años se han negociado hoy a 4,68% en EEUU, 3,25% en Alemania y 3,70% en España. La Reserva Federal (Fed) se descuenta por parte de la Fed en diciembre una subida de 27,5 puntos básicos, y en marzo 2027 una subida de 39,7 puntos básicos. El BCE se descuenta por parte del BCE una subida de 44 puntos básicos, y en marzo

De nuevo, ha repetido sistemáticamente un párrafo hasta básicamente quedarse sin tokens. Le planteé esto a Claude y me contestó que introdujese penalizaciones por repetirse, tales como:

```
response = model.create_chat_completion(  
    ...  
    repeat_penalty=1.3, # ← añadir esto (1.0=sin penalización, >1=penaliza repetición)  
    presence_penalty=0.5, # ← penaliza tokens que ya aparecieron  
    frequency_penalty=0.3, # ← penaliza tokens según su frecuencia  
)
```

Pero el resultado fue el mismo. Incluso, curiosamente, en uno de los casos le dio por contestarme con un comentario escrito en gran parte en portugués. Finalmente le pregunté si no estaríamos ante un caso de overfitting, teniendo en cuenta que el número de ejemplos prompt/comentario habían sido reducidos, y la cantidad de épocas bastante alto en términos relativos. Y Claude contestó:

¡Muy buena reflexión, y casi seguro que has dado en el clavo!

Sí, casi con certeza es overfitting

Los síntomas que describes son exactamente los del overfitting en fine-tuning de LLMs:

- ***Repetición de párrafos:*** el modelo "memoriza" patrones estructurales de los ejemplos en lugar de aprender a generalizar.
- ***Cambio de idioma (portugués):*** cuando el modelo pierde el hilo por overfitting, cae en distribuciones de su preentrenamiento original, y Gemma 3 tiene mucho texto en portugués en su corpus base.
- ***Loss de 0.35 con 14 épocas y 18 ejemplos:*** una loss baja con tan pocos datos es precisamente la señal de overfitting. El modelo ha memorizado los 18 ejemplos en lugar de aprender el estilo.

¿Por qué ocurrió?

La regla general para fine-tuning con LoRA es que con menos de ~100 ejemplos reales, más de 3-5 épocas ya es arriesgado. Con 18 ejemplos y 14 épocas, el modelo ha visto cada ejemplo casi 14 veces, que es demasiado.

Qué hacer para el TFM

Tienes dos opciones según el tiempo disponible:

Opción A: Repetir el fine-tuning con menos épocas. *Con los mismos 18 ejemplos, prueba con 3-5 épocas y una loss objetivo de ~0.8-1.0. Paradójicamente una loss más alta generalizará mejor. También ayuda subir el dropout en la configuración LoRA a 0.1 si lo tienes a 0.*

Opción B: Documentarlo como hallazgo del TFM. *Es perfectamente válido académicamente presentar el overfitting como conclusión: "Con 18 ejemplos y 14 épocas se produjo overfitting, evidenciado por repetición y cambio de idioma. La siguiente iteración debería limitarse a 3-5 épocas y ampliar el dataset a mínimo 50-100 ejemplos reales." Esto demuestra comprensión del proceso, que es exactamente lo que valora un profesor de MLOps.*

Pues sí, parece que estamos ante un caso de overfitting, que tendremos que resolver en el futuro. Sencillamente, los siguientes pasos será ir acumulando ejemplos reales, que harán falta más del doble de los que tenemos actualmente. Podemos utilizar un número de épocas más reducido, no pasando de 5-6, para que la pérdida sea mínimamente aceptable, pongamos 1.0-1.2. Además, podemos utilizar quizás un modelo más potente, de unos 6-9 B. Con todo, la utilización de modelos pequeños me parece un área fascinante!